

Previsão da Utilização de Postos de Transformação de Distribuição com Técnicas de Aprendizagem Automática

Miguel Lopes – N° 1222183

Departamento de Engenharia Informática
Instituto Superior de Engenharia do Porto
Porto, Portugal

[1222183@isep.ipp.pt]

Rui Margarido – N° 1230420

Departamento de Engenharia Informática
Instituto Superior de Engenharia do Porto
Porto, Portugal

1230420@isep.ipp.pt

Resumo—A gestão eficiente da rede de distribuição de energia elétrica requer conhecimento antecipado do nível de utilização dos seus ativos. Este trabalho aplica técnicas de aprendizagem automática supervisionada a 72 027 Postos de Transformação de Distribuição (PTDs), abordando duas tarefas complementares: regressão para prever a folga disponível em kVA (*PFolga_PTD*) e classificação para categorizar cada PTD em três níveis de utilização (*baixo, médio, alto*). Avaliaram-se cinco algoritmos por tarefa, com validação cruzada na regressão e validação cruzada estratificada na classificação ($k = 5$) e otimização de hiperparâmetros em duas fases por *GridSearchCV*. Na regressão, a Rede Neuronal obteve o melhor resultado ($R^2 = 0,4784$, $RMSE = 134,89$), superando a regressão linear simples em 217%. Na classificação, a Rede Neuronal foi igualmente o modelo superior (F1-score macro = 0,6669), e a superioridade face à Árvore de Decisão foi confirmada por teste t emparelhado ($p = 0,0038 < \alpha = 5\%$). A classe *médio* revelou-se a mais difícil de prever, o que se explica pela sua posição de transição no espaço de atributos.

Index Terms—aprendizagem automática, rede de distribuição elétrica, posto de transformação, regressão, classificação, validação cruzada

I. INTRODUÇÃO

A rede elétrica de distribuição em baixa tensão constitui a infraestrutura que liga as fontes de produção de energia aos consumidores finais. No contexto da transição energética, a crescente penetração de energias renováveis e de prosumidores (consumidores que também produzem energia), nomeadamente através de painéis fotovoltaicos, introduz novas dinâmicas de fluxo que tornam a gestão eficiente desta rede cada vez mais crítica [1].

Os Postos de Transformação de Distribuição (PTDs) são os equipamentos que convertem a tensão média em baixa tensão, servindo diretamente os consumidores finais. Cada PTD possui uma capacidade instalada em kVA e um nível de utilização que varia em função da procura associada. A sobrecarga de PTDs pode comprometer a qualidade e a continuidade do fornecimento de energia, enquanto PTDs subaproveitados representam ineficiência no uso do capital investido [2].

A previsão automática do nível de utilização dos PTDs, com base nas suas características técnicas e nos padrões de con-

sumo agregados, pode apoiar a tomada de decisão na gestão de ativos, planeamento da rede e priorização das intervenções de manutenção ou reforço. A aprendizagem automática tem demonstrado capacidade para captar relações complexas neste tipo de dados técnicos [7].

Este trabalho aborda o problema sob duas perspetivas complementares:

- 1) **Regressão**: prever o valor contínuo de folga disponível na rede (*PFolga_PTD*), em kVA, como indicador direto da margem de segurança operacional;
- 2) **Classificação**: categorizar cada PTD num dos três níveis de utilização da rede *baixo, médio* ou *alto*.

Em cada tarefa foram avaliados cinco algoritmos de aprendizagem automática, seguindo uma metodologia estruturada que inclui análise exploratória de dados, pré-processamento, otimização de hiperparâmetros em duas fases e análise estatística da significância dos resultados.

O artigo está organizado do seguinte modo: a Secção II apresenta o estado da arte; a Secção III descreve o conjunto de dados; a Secção IV apresenta a análise exploratória; a Secção V detalha a metodologia; as Secções VI e VII reportam os resultados; a Secção VIII analisa os resultados; e a Secção IX conclui o trabalho.

II. ESTADO DA ARTE

A. Algoritmos de Aprendizagem Automática

Árvores de Decisão e Regressão - O algoritmo CART [4] constrói árvores de forma recursiva, selecionando em cada nó a variável e o limiar que minimiza a impureza (Gini ou entropia na classificação; MSE na regressão). A poda por custo-complexidade [4] controla a generalização, limitando a profundidade máxima. A principal vantagem é a interpretabilidade direta: a importância de cada variável é derivada da redução de impureza acumulada nos nós que a utilizam.

Support Vector Machines - As SVMs [4] maximizam a margem entre classes no espaço transformado por uma função kernel. No problema de regressão, o Support Vector Regression (SVR) minimiza o erro com margem ϵ : previsões

dentro da banda $\pm\epsilon$ não são penalizadas. O parâmetro C controla o equilíbrio entre a margem máxima e a penalização das violações. Em classificação, o kernel é utilizado com γ para controlar a curvatura da fronteira de decisão [4].

K-Vizinhos-mais-Próximos - O KNN [4] classifica uma observação com base na maioria dos K vizinhos mais próximos no espaço de atributos (utilizando distância euclidiana ou de Manhattan). Não existe fase de treino explícita, mas o custo de previsão é $O(n)$. A ponderação por distância ($weights='distance'$) melhora o desempenho quando os vizinhos mais próximos são mais informativos. O algoritmo é sensível à escala das variáveis, sendo indispensável a standardização prévia [4].

Redes Neurais Artificiais - O Perceptrão Multicamada (MLP) com *backpropagation* [4] aproxima funções arbitrariamente complexas através de camadas densas com funções de activação não lineares (*relu*, *tanh*). O optimizador Adam adapta a taxa de aprendizagem para cada parâmetro. A regularização L_2 (parâmetro α) penaliza pesos elevados; o *early stopping* interrompe o treino quando o desempenho na validação interna deixa de melhorar, actuando como regularização implícita [4].

B. Avaliação e Comparação de Modelos

A validação cruzada estratificada k -fold [4] estima o desempenho de generalização de forma não viesada, garantindo a representatividade das classes em cada partição. Para a regressão, as métricas padrão são o erro absoluto médio (MAE), a raiz do erro quadrático médio (RMSE) e o coeficiente de determinação R^2 . Em problemas de classificação com classes desequilibradas, o F1-score macro é preferível à accuracy, por atribuir igual importância ao desempenho em cada classe [3].

A significância estatística das diferenças de desempenho é avaliada com testes emparelhados sobre os resultados por fold. O teste de Shapiro-Wilk verifica a normalidade das diferenças e conforme o resultado, aplica-se o teste t emparelhado ou o teste de Wilcoxon [8].

C. ML em Redes de Distribuição Elétrica

A aprendizagem automática tem sido aplicada ao diagnóstico e planeamento de redes elétricas, nomeadamente na previsão de carga e identificação de padrões de consumo em contadores inteligentes [7], bem como na deteção de anomalias e otimização de recursos. A disponibilidade crescente de dados técnicos dos PTDs cria oportunidades para modelos de previsão baseados em dados que complementam os métodos analíticos tradicionais.

III. CONJUNTO DE DADOS

O conjunto de dados, disponibilizado pela E-Redes [2] (operadora da rede de distribuição elétrica em Portugal), descreve 72 027 PTDs com variáveis técnicas, indicadores agregados ao nível do município e informação geográfica. As principais variáveis explicativas são:

- *Cap_PTD_kVA*: capacidade instalada do PTD (kVA);
- *N_Clientes*: número de clientes ligados ao PTD;

- *Pot_Contratada_kVA*: potência total contratada;
- *N_PTDs_Concelho*: número de PTDs no município;
- *Tipo Construtivo*: tipo de instalação (Aéreo-AS, Aéreo-AI, Cabine, etc.), variável categórica;
- *P_IP_Total*: potência de iluminação pública instalada;
- *Clientes_Produtores_Ratio*: rácio de prosumidores.

A variável alvo de **regressão** é *PFolga_PTD* (folga disponível em kVA):

$$PFolga_PTD = Cap_PTD_kVA \times 0,92 \times (1 - Util_Decimal) \quad (1)$$

onde *Util_Decimal* é a taxa de utilização real e o fator 0,92 representa a margem de segurança operacional.

A variável alvo de **classificação** é *utilizRede*, obtida por discretização de *Util_Decimal* em três classes por quantis: *baixo* ($\leq 0,39$), *médio* ($0,39-0,59$) e *alto* ($> 0,59$).

IV. ANÁLISE EXPLORATÓRIA DE DADOS

A análise exploratória de dados (AED) teve três objetivos: (1) caracterizar as distribuições das variáveis alvo e identificar outliers e assimetrias; (2) quantificar as correlações entre variáveis explicativas e variáveis alvo, para fundamentar a seleção de variáveis; e (3) validar as escolhas de pré-processamento antes da fase de modelação.

A. Variável Alvo de Regressão: *PFolga_PTD*

O histograma da Fig. 1 mostra que *PFolga_PTD* é fortemente assimétrica à direita: mediana de 77,28 kVA, média de 147,98 kVA e máximo de 4 489,60 kVA. A diferença acentuada entre mediana e média indica que uma minoria de PTDs com capacidade muito elevada puxa a média para cima. Estes valores extremos são reais (PTDs de grande porte em zonas industriais ou urbanas densas) e não devem ser removidos. Contudo, afetam o RMSE de forma quadrática, tornando esta métrica mais sensível a grandes erros individuais do que o MAE. A grande amplitude de escala (de 0 a $\approx 4 490$ kVA) torna indispensável a standardização antes de modelos sensíveis à escala (SVM, KNN, Rede Neuronal).




Figura 1. Distribuição de *PFolga_PTD*. A forte assimetria positiva e a presença de outliers justificam o uso de RMSE e MAE como métricas complementares e tornam obrigatória a standardização.

B. Variável Alvo de Classificação: utilizRede

A Fig. 2 apresenta a distribuição das três classes de *utilizRede*. A classe *baixo* representa $\approx 51.1\%$ dos PTDs, *alto* $\approx 24.0\%$ e *médio* $\approx 24.9\%$. Este desequilíbrio tem duas implicações diretas: (i) a *accuracy* não é uma métrica adequada, pois um classificador que preveja sempre *baixo* atingiria $\approx 51.1\%$ sem aprender nada; (ii) o **F1-score macro** é a métrica de referência, pois atribui igual peso ao desempenho em cada classe, penalizando os erros na classe minoritária (*médio*).




Figura 2. Distribuição das classes de *utilizRede*. O desequilíbrio moderado (51.1% baixo, 24.9% médio, 24.0% alto) justifica o F1-score macro como métrica principal de classificação.

A Fig. 3 relaciona as duas variáveis alvo através de um boxplot de *PFolga_PTD* por classe. Os resultados confirmam a consistência física da discretização: PTDs com utilização *baixa* têm folgas medianas elevadas, enquanto PTDs com utilização *alta* têm folgas próximas de zero. A classe *médio* apresenta distribuição intermédia com maior sobreposição face às classes vizinhas, o que antecipa a dificuldade de a classificar corretamente, fenómeno confirmado posteriormente na matriz de confusão.




Figura 3. Boxplot de *PFolga_PTD* por classe de *utilizRede*. A sobreposição da classe *médio* com as classes adjacentes antecipa a sua maior dificuldade de classificação.

C. Correlações e Seleção de Variáveis

O mapa de calor da Fig. 4 quantifica as correlações de Pearson entre variáveis numéricas. *Cap_PTD_kVA* ($r \approx 0,92$) e *Cap_per_Cliente* ($r \approx 0,60$) têm as correlações mais elevadas com *PFolga_PTD*, mas constituem *data leakage* (Tabela I). Entre as variáveis disponíveis, *P_IP_Total* apresenta a maior correlação ($r = 0,388$), justificando o seu uso na regressão linear simples.

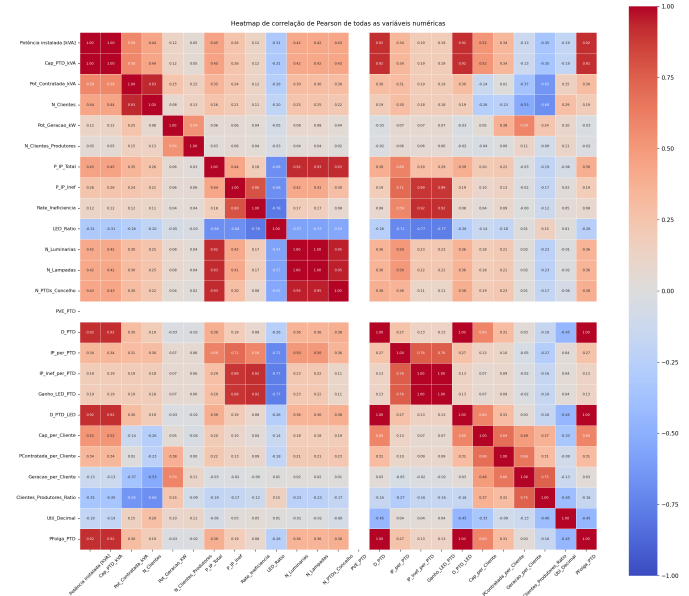


Figura 4. Mapa de calor das correlações de Pearson. Valores em laranja/vermelho indicam correlação positiva forte. As variáveis com *leakage* (*Cap_PTD_kVA*, *Util_Decimal*) foram excluídas da regressão.

A Tabela I resume os critérios de exclusão de variáveis. Para a classificação, *Cap_PTD_kVA* foi reintegrada (19 features no total), pois não integra a fórmula de *utilizRede*.

Tabela I
VARIÁVEIS EXCLUÍDAS E RESPECTIVA JUSTIFICAÇÃO

Variável(eis)	Razão
<i>Cód. Instalação</i> , <i>Cod-DistritoConcelho</i>	Identificadores sem valor preditivo
<i>Coordenadas Geográficas</i>	Substituída por <i>Latitude/Longitude</i>
<i>Concelho</i>	Cardinalidade muito elevada
<i>PVE_PTD</i>	Constante (único valor único)
<i>Pot. instalada [kVA]</i>	Duplicado exato de <i>Cap_PTD_kVA</i>
<i>Pot_Geracao_kW</i> , <i>Geracao_per_Cliente</i>	Relativas à produção, não ao consumo
<i>Nível Utilização [%]</i>	Versão textual de <i>Util_Decimal</i>
Exclusões adicionais apenas na regressão:	
<i>Cap_PTD_kVA</i> , <i>Util_Decimal</i>	Componentes diretos da fórmula (<i>leakage</i>)
<i>Cap_per_Cliente</i>	Derivada de <i>Cap_PTD_kVA</i> (<i>leakage</i> indireto)

D. Pré-processamento

Com base nas conclusões da AED, aplicaram-se as seguintes transformações antes da modelação [6]: standardização ($\mu = 0$, $\sigma = 1$) de todas as variáveis numéricas com *StandardScaler* integrado em *pipeline* (evita fuga de informação entre folds); codificação de *Tipo Construtivo* com *One-Hot Encoding (OHE)*; e codificação da variável alvo de classificação com *LabelEncoder* (em *baixo*, *médio* e *alto*). Registos com valores omissos nas variáveis alvo foram removidos ($\approx 4,25\%$ do total).

Em síntese, a AED motivou três decisões metodológicas: uso de MAE e RMSE como métricas complementares na regressão (assimetria de *PFolga_PTD*); F1-score macro na classificação (desequilíbrio de *utilizRede*); e standardização obrigatória para SVM, KNN e NN (amplitude de escala).

V. METODOLOGIA

Todos os modelos foram avaliados por validação cruzada com $k = 5$ folds [4], [5]. Na tarefa de regressão, foi utilizada validação cruzada simples através de *KFold*, uma vez que a variável alvo é contínua. Na tarefa de classificação, foi utilizada validação cruzada estratificada através de *StratifiedKFold*, de forma a preservar, em cada fold, a proporção das classes da variável alvo. As métricas de regressão consideradas foram MAE, RMSE e R^2 ; na classificação, utilizou-se o F1-score macro [3], por ser uma métrica adequada em contextos com desequilíbrio entre classes. A otimização de hiperparâmetros decorreu em duas fases: **Fase 1** - seleção de configuração, como arquitetura, kernel ou valor de K , por validação cruzada; **Fase 2** - afinação da regularização por *GridSearchCV* [3]. Os dois melhores modelos de cada tarefa foram comparados por testes emparelhados ($\alpha = 5\%$): teste t quando as diferenças por fold apresentaram normalidade, avaliada pelo teste de Shapiro-Wilk, e teste de Wilcoxon [8] caso contrário.

VI. REGRESSÃO

A. Diagrama de Correlação

A Fig. 5 apresenta a correlação de Pearson de cada variável explicativa numérica com *PFolga_PTD*. As variáveis categóricas (*Tipo Construtivo*) foram excluídas desta análise, pois a correlação de Pearson mede apenas associação linear entre variáveis contínuas. As variáveis com *data leakage* (*Cap_PTD_kVA*, *Util_Decimal*, *Cap_per_Cliente*) foram igualmente excluídas por serem componentes da fórmula de *PFolga_PTD*.

Entre as variáveis candidatas, *P_IP_Total* apresenta a maior correlação absoluta ($r = 0,388$), tornando-se o preditor da regressão linear simples.

B. Regressão Linear Simples

A Regressão Linear Simples (RLS) usa *P_IP_Total* como único preditor ($r = 0,388$, o mais elevado disponível). O modelo é ajustado por mínimos quadrados ordinários e avaliado por validação cruzada ($k = 5$, *cross_val_predict*). A função estimada, treinada em todos os dados, é:

$$PFolga_PTD = 89,63 + 0,0421 \times P_IP_Total \quad (2)$$




Figura 5. Correlações de Pearson das variáveis explicativas com *PFolga_PTD*. *P_IP_Total* tem o maior $|r|$ entre as variáveis sem *leakage*.

O coeficiente $\beta_1 = 0,0421 > 0$ confirma a relação positiva esperada, mas a sua magnitude reduzida e a Fig. 6 evidenciam que um único preditor linear é insuficiente.




Figura 6. Diagrama de dispersão e reta de regressão linear simples (esquerda: visão geral; direita: zoom na região mais densa).

Os erros obtidos por k -fold foram MAE=112,73, RMSE=172,10 e $R^2 = 0,1508$: a RLS explica apenas $\approx 15\%$ da variabilidade de *PFolga_PTD* e serve de **baseline**, ou seja, qualquer modelo seguinte deve superar RMSE < 172 e $R^2 > 0,15$.

C. Modelos de Regressão com Múltiplas Variáveis

Regressão Linear Múltipla (RLM) - Usa *forward selection* para identificar o subconjunto de features que minimiza o RMSE em k -fold. Variáveis categóricas entram como grupos OHE completos.

Árvore de Regressão - *GridSearchCV* sobre $max_depth \in \{5, 10\}$ e $min_samples_leaf \in \{5, 10\}$ selecionou $max_depth=10$, $min_samples_leaf=10$, $criterion=squared_error$ (RMSE=139,38). Não requer standardização.

LinearSVR - Comparação de kernels em subsample de 10 000 obs.: kernel linear (RMSE=139,10) superou RBF

(142,43) e polinomial (142,81), justificando *LinearSVR* no *dataset* completo. *GridSearchCV* selecionou $C=0,1$, $\epsilon=0$, $loss=squared_epsilon_insensitive$.

Rede Neuronal (NN) - Fase 1: 18 configurações (9 arquiteturas $\times relutanh$); melhor: (200,) + $tanh$. Fase 2: $\alpha=0,01$, $lr=0,01$ (convergência rápida, sem oscilações). *Early stopping* parou na **época 59** ($n_iter_no_change=10$, $validation_fraction=0,1$). A Fig. 7 mostra a evolução do RMSE por época.




Figura 7. Curvas de RMSE e R^2 por época da Rede Neuronal (regressão). O *early stopping* interrompeu na época 59 (linha verde a tracejado), onde a loss de validação estabilizou em $RMSE \approx 132$ e $R^2 \approx 0,48$.

D. Comparação de Modelos e Variáveis Relevantes

A Tabela II resume os resultados por k -fold cross-validation ($k = 5$). A Rede Neuronal obteve o melhor desempenho em todas as métricas: $R^2 = 0,4784$, melhoria de 217% sobre a RLS e de 12% sobre a RLM. A RLM e o LinearSVR são praticamente equivalentes, evidenciando que ambos exploram a mesma componente linear dos dados.

Tabela II
RESULTADOS DE REGRESSÃO (MÉDIA, $k = 5$ FOLDS)

Modelo	MAE	RMSE	R^2
Reg. Linear Simples	112,73	172,10	0,1508
Reg. Linear Múltipla	82,70	141,38	0,4269
Árvore de Regressão	79,17	139,40	0,4428
LinearSVR	82,67	141,38	0,4269
Rede Neuronal	77,11	134,89	0,4784

A Fig. 8 ilustra as diferenças de desempenho entre modelos. A RLM e o LinearSVR obtêm RMSE idêntico (141,38) porque ambos minimizam o erro quadrático no espaço linearizado. A Árvore de Regressão supera o LinearSVR (RMSE 139,40 vs 141,38) porque captura interações locais entre Tipo Construtivo e $N_PTDs_Concelho$ que o modelo linear não consegue representar. A Rede Neuronal supera a Árvore (134,89 vs 139,40) por modelar relações contínuas e suaves que as partições binárias da árvore apenas aproximam em escada.

Existe convergência entre modelos quanto às variáveis mais relevantes: $N_PTDs_Concelho$ e as variáveis de tipo construtivo ($TC_Aéreo-AS$, TC_Cabine) surgem no top-3 de todos os modelos. A folga da rede está primariamente associada à densidade de PTDs no município e ao tipo de infraestrutura elétrica. A NN identifica adicionalmente $N_Clientes$ como




Figura 8. Comparação dos modelos de regressão (MAE, RMSE, R^2). A NN é superior em todas as métricas; RLM e LinearSVR são equivalentes, evidenciando que exploram a mesma componente linear dos dados.

variável relevante, relação não-linear que os modelos lineares captam de forma menos directa.

A Rede Neuronal é o modelo recomendado: RMSE = 134,89 kVA representa uma redução de 21,6% face à *baseline* (RLS: 172,10) e de 4,6% face à RLM, mantendo $R^2 = 0,4784$ contra 0,4269 da RLM.

E. Curvas de Aprendizagem

A Fig. 9 compara as curvas de aprendizagem dos dois melhores modelos. A Rede Neuronal apresenta gap treino/validação de $\approx 4,5\%$, estável desde os 30% dos dados, a regularização L2 e o *early stopping* (época 59) evitaram *overfitting*; ambas as curvas têm RMSE decrescente (sem *underfitting*). A Árvore de Regressão tem gap de $\approx 5\%$, mas com instabilidade para conjuntos pequenos ($< 20\%$), indicando que as partições binárias precisam de volume mínimo para estabilizar. Com $> 60\%$ dos dados, ambos estabilizam sem divergência, confirmando boa generalização.




Figura 9. Curvas de aprendizagem dos dois melhores modelos de regressão. Gap de $\approx 4,5\%$ (NN) e $\approx 5\%$ (Árvore) indicam boa generalização sem *overfitting*.

F. Análise de Significância Estatística

Para verificar se a diferença de RMSE entre a Rede Neuronal (134,89) e a Árvore de Regressão (139,40) é estatisticamente significativa, calcularam-se as diferenças por fold: $\Delta_i = RMSE_{NN,i} - RMSE_{DT,i}$, para $i = 1, \dots, 5$. O teste de Shapiro-Wilk verificou a normalidade das diferenças e em função do resultado, aplicou-se o teste t emparelhado ou o de Wilcoxon [8] ($\alpha = 5\%$). A limitação estrutural é que com $k = 5$ folds, o p-valor mínimo possível do Wilcoxon é $0,0625 > 5\%$, pelo que este teste nunca pode rejeitar H_0 a 5% com apenas 5 observações. Como a normalidade foi garantida o teste t emparelhado é o mais adequado e foi possível verificar que existe evidência estatística a 5% ($p = 0,002$) para afirmar

que a NN é o melhor Modelo. Independentemente do resultado formal, a melhoria de 4,6% no RMSE é consistente ao longo dos 5 folds (nenhum fold inverte a ordenação), o que, aliado ao $\Delta R^2 = 0,0356$, fundamenta a recomendação da Rede Neuronal.

As variáveis que mais explicam *PFolga_PTD*, dimensionamento técnico e densidade municipal de PTDs, são também relevantes para a tarefa de classificação do nível de utilização, como confirma a análise seguinte.

VII. CLASSIFICAÇÃO

A. Modelos e Otimização

Baseline - Prevê sempre *baixo* (classe majoritária); F1-mac. = 0,225.

Árvore de Decisão - *GridSearchCV* [3] sobre $max_depth \in \{3, 5, 7, 10, 15, \emptyset\}$, $min_samples_leaf \in \{1, 5, 10, 25\}$ e critério $\in \{gini, entropy\}$, com $class_weight="balanced"$ [4]. Melhor configuração: $max_depth=10$, $min_samples_leaf=25$, $criterion=gini$.

Rede Neuronal - Fase 1: múltiplas arquiteturas $\times$ ativação (*relu*); Fase 2: afinação de α e lr (*Adam*) [4]. *Early stopping* com paciência = 10 épocas sobre log-loss de validação.

SVM - Comparação de kernels em amostra estratificada de 20 000 obs. (custo $O(n^2)-O(n^3)$) [4]: *linear* (F1=0,627) superou *rbf* (0,623) e *poly* (0,566). Fase 2: $C=10$, $\gamma=scale$.

KNN - Fase 1: $K \in \{3, 5, 7, 9, 11, 15, 21, 31, 41\}$; $K=9$ maximiza F1 (0,535) [4]. Fase 2: $weights=distance$, $metric=euclidean$ (F1=0,547). Avaliado sobre amostra de 20 000 obs.

B. Resultados

A Tabela III sintetiza os resultados ($k = 5$); F1-score macro é a métrica principal dado o desequilíbrio de classes [3].

Tabela III
RESULTADOS DE CLASSIFICAÇÃO (MÉDIA $\pm$ DP, $k=5$ FOLDS)

Modelo	Acc.	Prec.	Rec.	F1-mac.
Baseline	0,511 $\pm$ 0,000	0,170 $\pm$ 0,000	0,333 $\pm$ 0,000	0,225 $\pm$ 0,000
Árvore DT	0,689 $\pm$ 0,005	0,659 $\pm$ 0,005	0,654 $\pm$ 0,005	0,655 $\pm$ 0,005
NN	0,717 $\pm$ 0,003	0,682 $\pm$ 0,006	0,660 $\pm$ 0,005	0,668 $\pm$ 0,006
SVM*	0,694 $\pm$ 0,005	0,644 $\pm$ 0,007	0,629 $\pm$ 0,005	0,628 $\pm$ 0,006
KNN*	0,615 $\pm$ 0,007	0,554 $\pm$ 0,006	0,545 $\pm$ 0,007	0,547 $\pm$ 0,006

* Amostra de 20 000 obs.; dp: desvio padrão.

A NN é o melhor modelo em todas as métricas globais; o KNN é o pior. A Tab. IV decompõe os resultados por classe para os dois melhores modelos.

A NN supera a DT nas classes *baixo* (F1: 0,826 vs 0,797) e *alto* (0,687 vs 0,668). A DT tem recall ligeiramente superior na classe *médio* (0,533 vs 0,452), sugerindo que as suas fronteiras de decisão recortam melhor a zona de transição. A classe *médio* é a mais difícil em ambos os modelos, por definição, ocupa o espaço de transição onde pequenas variações nas features mudam a classificação.

A Fig. 10 confirma esta análise na matriz de confusão.

Tabela IV
PRECISÃO, RECALL E F1 POR CLASSE (CROSS_VAL_PREDICT, $k = 5$)

Modelo	Classe	Prec.	Rec.	F1
NN	baixo	0,779	0,878	0,826
	médio	0,537	0,452	0,491
	alto	0,729	0,650	0,687
DT	baixo	0,808	0,786	0,797
	médio	0,472	0,533	0,501
	alto	0,696	0,642	0,668




Figura 10. Matriz de confusão da Rede Neuronal (resultados agregados de validação cruzada). A classe *médio* apresenta o maior número de erros, confirmando a dificuldade de separar a zona de transição.

A superioridade da NN sobre a Árvore DT foi confirmada por teste t emparelhado sobre os F1-score macro dos 5 folds: $p = 0,0038 < \alpha = 5\%$ (Shapiro-Wilk confirmou normalidade das diferenças). A análise detalhada está na Secção VIII.




Figura 11. Curvas de log-loss e accuracy por época (NN, classificação). A convergência da loss de validação e o gap reduzido confirmam boa generalização; *early stopping* interrompeu antes das 200 épocas máximas.

C. Importância de Features

A Fig. 13 mostra as 15 variáveis mais importantes na Árvore de Decisão. *Pot_Contratada_kVA* (0,371) e *Cap_PTD_kVA* (0,314) dominam, seguidas de *Clientes_Produtores_Ratio* (0,167).

Comparando com as correlações da AED: *Pot_Contratada_kVA* e *Cap_PTD_kVA* têm correlação




Figura 12. Comparação dos modelos de classificação (Accuracy, Precision, Recall, F1-score macro). A NN lidera em todas as métricas; o KNN é o pior modelo.




Figura 13. Importância das 15 variáveis mais relevantes na Árvore de Decisão de classificação (redução de impureza acumulada).

linear moderada com *Util_Decimal*, mas a sua importância na árvore é muito superior, evidência de relações não-lineares capturadas pelo modelo. *N_Clientes* tem correlação razoável mas baixa importância na árvore, pois a sua informação é absorvida por variáveis correlacionadas como *Pot_Contratada_kVA*. As variáveis de iluminação pública que lideraram a correlação com *PFolga_PTD* têm importância residual para *utilizRede*, o nível de utilização depende fundamentalmente do dimensionamento técnico e da procura contratada.

D. Curvas de Aprendizagem

A Fig. 14 compara a eficiência do treino dos quatro modelos. O **melhor modelo** (NN, F1-mac.=0,668, Acc.=0,717) apresenta curvas convergentes desde $\approx 40\%$ dos dados, com gap estável e reduzido: a regularização L2 e o *early stopping* evitaram memorização. O **pior modelo** (KNN, F1-mac.=0,547, Acc.=0,615) tem o maior gap treino–validação: com 19 features, a distância euclidiana no espaço de alta dimensão perde discriminância [4], e mesmo com *weights* = distance o modelo não generaliza tão bem quanto os baseados em árvore. A **Árvore DT** (F1-mac.=0,655, Acc.=0,689) converge rapidamente e de forma estável, a melhor relação custo–desempenho–interpretabilidade do grupo. O **SVM** (F1-mac.=0,628, Acc.=0,694 na amostra) apresenta curvas próximas, mas a expressividade do kernel linear é insuficiente para captar a fronteira complexa da classe *médio*.




Figura 14. Curvas de aprendizagem dos modelos de classificação (F1-score macro). NN (melhor): gap reduzido e estável; KNN (pior): maior lacuna treino–validação.

VIII. DISCUSSÃO E ANÁLISE ESTATÍSTICA

A. Significância Estatística

Em ambas as tarefas, a Rede Neuronal emergiu como o modelo de melhor desempenho, com a não-linearidade a acrescentar valor: na regressão, confirmado por teste t ($p = 0,002 < \alpha = 5\%$); $\Delta R^2 \approx 0,05$ e redução de 4,6% no RMSE face à segunda melhor (Árvore DT). Na classificação confirmado por teste t emparelhado ($p = 0,0038 < \alpha = 5\%$).

Para a classificação, verificou-se se a diferença de F1-score macro entre a NN e a Árvore DT é estatisticamente significativa. O teste de Shapiro-Wilk confirmou a normalidade das diferenças $\Delta F1 = F1_{NN} - F1_{DT}$ por fold. Aplicou-se o teste t emparelhado, que produziu $p = 0,0038 < \alpha = 0,05$, rejeitando H_0 . A Rede Neuronal é estatisticamente superior à Árvore de Decisão na tarefa de classificação.

Note-se que, com $k = 5$ folds, o teste de Wilcoxon [8] tem potência limitada: o p-valor mínimo possível é $0,0625 > 5\%$. O teste t é mais adequado quando a normalidade das diferenças está garantida, como acontece aqui.

B. Limitações

- **Classe médio e desequilíbrio:** com $\approx 20\%$ de observações, o F1 desta classe é o mais baixo em todos os modelos (NN: 0,491; DT: 0,501). Técnicas SMOTE ou *class_weights* reforçados poderiam reduzir a taxa de erro nesta classe crítica.
- **Amostragem do SVM e KNN:** avaliados em 20 000 obs. (28% do dataset), os resultados podem diferir no conjunto completo; e a discretização de *utilizRede* por quantis cria fronteiras arbitrárias que limites operacionais físicos tornariam mais relevantes.

C. Trabalho Futuro

As principais direções de melhoria incluem: (1) modelos ensemble (Random Forest, Gradient Boosting), que reduzem

a variância por combinação de múltiplas árvores e tipicamente superam modelos individuais na presença de ruído [4]; (2) incorporação de variáveis temporais e climáticas para captar sazonalidade; (3) técnicas de balanceamento de classes (SMOTE, oversampling ponderado) para melhorar o F1 da classe *médio*; e (4) validação externa com dados de períodos distintos dos usados no treino, para avaliar a estabilidade temporal dos modelos.

IX. CONCLUSÕES

Este trabalho aplicou cinco algoritmos de aprendizagem automática a um conjunto de dados de 72 027 PTDs, avaliando o seu desempenho em regressão e classificação da utilização da rede.

Na **regressão**, a Rede Neuronal foi o modelo com melhor desempenho ($R^2 = 0,4784$, RMSE = 134,89, MAE = 77,11), com melhoria de 12% no R^2 face à regressão linear múltipla e de 217% face à simples. Os modelos lineares e o LinearSVR mostraram desempenho equivalente, sugerindo que a não linearidade capturada pela NN e pela Árvore de Regressão contribui genuinamente para melhorar a previsão.

Na **classificação**, a Rede Neuronal obteve F1-score macro de 0,6669, superior à Árvore de Decisão (0,6552) e muito acima da baseline (0,2254). A diferença face à Árvore de Decisão é estatisticamente significativa ($p = 0,0038$, teste t emparelhado, $\alpha = 5\%$). A classe *médio* permanece a mais difícil de prever, evidenciando que a zona de transição no espaço de atributos carece de variáveis explicativas adicionais.

A análise de importância de variáveis revelou que o dimensionamento técnico dos PTDs (*Pot_Contratada_kVA*, *Cap_PTD_kVA*) é o factor mais determinante para a classificação do nível de utilização, o que é fisicamente coerente. Na regressão, a densidade de PTDs no município e o Tipo Construtivo são as variáveis dominantes. A convergência parcial entre as variáveis mais relevantes das duas tarefas sugere que um modelo multitarefa com representações partilhadas poderia captar estas relações de forma mais eficiente.

Do ponto de vista operacional, os dois modelos fornecem sinais complementares: a regressão (NN, RMSE = 134,89 kVA) quantifica a folga disponível como indicador de urgência; a classificação (NN, F1 = 0,668) categoriza o risco de forma accionável. PTDs classificados como *alto* com *PFolga_PTD* próxima de zero representam os casos prioritários para planeamento de reforço. O uso de modelos ensemble e a inclusão de variáveis temporais constituem as principais direções de melhoria identificadas.

REFERÊNCIAS

- [1] H. Farhangi, “The path of the smart grid,” *IEEE Power and Energy Magazine*, vol. 8, n.º 1, pp. 18–28, 2010.
- [2] E-Redes, “Dados Abertos, Postos de Transformação de Distribuição,” <https://www.e-redes.pt/pt-pt>, acessado em 2025.
- [3] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. Disponível em: <https://scikit-learn.org/stable/>
- [4] C. M. Bishop, *Pattern Recognition and Machine Learning*. Nova Iorque: Springer, 2006.
- [5] T. M. Mitchell, *Machine Learning*. Nova Iorque: McGraw-Hill, 1997.
- [6] W. McKinney, *Python for Data Analysis*, 3.ª ed. Sebastopol, CA: O’Reilly Media, 2022. Disponível em: <https://wesmckinney.com/book/>
- [7] S. Haben, C. Singleton e P. Grindrod, “Analysis and clustering of residential customers energy behavioral demand using smart meter data,” *IEEE Transactions on Smart Grid*, vol. 7, n.º 1, pp. 136–144, 2016.
- [8] F. Wilcoxon, “Individual comparisons by ranking methods,” *Biometrics Bulletin*, vol. 1, n.º 6, pp. 80–83, 1945.